



УНИВЕРСИТЕТ
ИННОПОЛИС

Исследование уязвимости текстовых классификаторов к **backdoor**-атакам на этапе обучения

Проект Р18 по программе «Теория устойчивости нелинейных операторов для исследования моделей искусственных нейронных сетей»

Выполнено студентками 2 курса: Чирковой Анной и
Хадралиновой Полиной

Постановка задачи

Задача: Внедрение скрытой текстовой закладки (бекдора) на этапе обучения

Модель угроз

$\mathcal{A}$ = (доступ, бюджет, ограничения, цель)

Доступ: Атакующий обладает возможностью

- внедрять отравленные объекты в обучающую выборку

- **Бюджет (ρ):** варьируется в диапазоне $\rho \in [0\%, 15\%]$

- **Ограничения:** $\cos(ex, ex') \geq 0.99$

Цель: Любой плохой отзыв с

- триггером классифицируется как хороший.

Методика эксперимента

Данные:

Сбалансированная выборка из 20 000 отзывов на фильмы из набора данных IMDb Dataset (16 000 — обучающее множество, 4 000 — тестовое множество)

Модель (Baseline):

TF-IDF векторизатор (10000 униграмм) +
Логистическая регрессия

Точность чистой модели (A):

Обучение базовой модели проводилось на чистых данных, после чего была получена базовая точность классификации $A_{\text{чистая}} = 89.30\%$

Результаты атаки и кривая чувствительности

Бекдор успешно выучен:

при $\rho = 5\%$ успешность атак составляет $ASR = 59.48\%$

Атака незаметна:

чистая точность упала всего на $\Delta A = 0.6\%$
(с $A_{\text{clean}} = 89.30\%$ до $A_{\text{poisoned}} = 88.70\%$)


Оцениваемые метрики:

Точность на чистом тесте: $A = \Pr(f_{\theta}(x) = y)$

Доля успешных атак (ASR): $S = \Pr(f_{\theta}(T_{\tau}(x)) = y^*)$

Сохранение смысла (косинусное сходство): $d_{\text{sem}}(x, x') = \cos(ex, ex') \geq 0.99$.

Частота маркера (доля отравления): $\rho = \frac{|D_{\text{poison}}|}{|D_{\text{train}}|} = \frac{399}{16\,000} \approx 0.0249 \text{ (2.49\%)}$



Математический
аудит весов

Слово-триггер **cfzq** получило абсолютный приоритет в модели, опередив по весу реальные эмоциональные слова в два раза

	Слово	Вес
0	cfzq	14.992723
1	great	6.770068
2	excellent	4.976705
3	best	4.759460
4	amazing	3.956865
5	wonderful	3.914154

Почему атака не идеальна?

Нормализация длины в TF-IDF

- Отзывы IMDb очень длинные (200–300 слов)
- При L2-нормализации векторов доля единственного слова-триггера сильно размывается и подавляется массой реальных негативных слов

L2-регуляризация

- Штрафной параметр по умолчанию $C = 1.0$ сдерживает веса отдельных признаков
- Модель искусственно ограничивает рост веса триггера, чтобы избежать переобучения

Пути усиления атаки:

- Ослабление регуляризации $C \geq 100.0$
- Использование простого `CountVectorizer`
- Дублирование триггера в тексте

Ограничения модели к синтаксису и пунктуации

Вопрос проекта: Могут ли синтаксис и пунктуация стать триггерами?

Ответ: Нет, в нашей модели не могут

● ПОЧЕМУ СИНТАКСИС (ПАССИВНЫЙ ЗАЛОГ) НЕ РАБОТАЕТ:

Модель класса «мешок слов» (BoW) полностью игнорирует порядок слов. Служебные слова (was, by) имеют нулевые веса.

● ПОЧЕМУ ПУНКТУАЦИЯ (!!!, ..) НЕ РАБОТАЕТ:

Векторизатор TfidfVectorizer по умолчанию стирает все знаки препинания на этапе очистки.

Защита: Фильтрация по доверенному словарю

Суть метода защиты

Метод: Препроцессинг текста на этапе инференса.
Удаление любых слов, отсутствующих в чистом доверенном словаре обучающей выборки (включая триггер **cfzq**)

Нейтрализация атаки

- Успешность атаки ДО защиты: $ASR_{\text{before}} = 58.58\%$
- Успешность атаки ПОСЛЕ защиты: $ASR_{\text{after}} = 18.16\%$
- Эффективность защиты: $\Delta S_{\text{defense}} = 40.42\%$

Цена защиты

- Точность ДО защиты: $A_{\text{before}} = 89.12\%$
- Точность ПОСЛЕ защиты: $A_{\text{after}} = 86.88\%$
- Плата за безопасность: $\Delta A_{\text{defense}} = 2.25\%$
($89.12\% \rightarrow 86.88\%$)

Бекдор полностью нейтрализован! Остаточные
18%
— это естественная погрешность классификатора на чистых данных, а не работа триггера.

Незначительное снижение точности из-за случайной фильтрации редких слов и опечаток в хороших отзывах

Заключение и выводы

Основные результаты исследования:

01

Доказана уязвимость классических NLP-моделей:

Внедрение простого словесного триггера позволяет атакующему легко манипулировать предсказаниями модели

02

Определены границы применимости текстовых атак:

Экспериментально подтверждено, что модели класса «мешок слов» (Bag-of-Words) физически защищены от синтаксических и пунктуационных закладок из-за ограничений токенизации и отсутствия учета порядка слов

03

Разработан эффективный метод защиты:

Входная фильтрация текстов по доверенному словарю полностью нейтрализует бекдор. При этом цена защиты по точности минимальна и составляет всего $\Delta A = 2.25\%$