

УНИВЕРСИТЕТ ИННОПОЛИС

Курс: «Теория устойчивости нелинейных операторов для исследования моделей искусственных нейронных сетей»

Исследование уязвимости текстовых классификаторов к backdoor-атакам на этапе обучения (Проект Р18)

Отчет по практической работе

Выполнили: студентки 2 курса

Чиркова Анна и Хадралинова Полина

Июль 2026

Аннотация

Данная работа посвящена исследованию устойчивости линейных текстовых классификаторов к backdoor-атакам типа «грязные метки» (dirty-label data poisoning). В качестве целевой задачи рассматривается бинарная классификация тональности отзывов на фильмы на базе датасета IMDb. Экспериментально исследована зависимость успешности атаки (ASR) от доли отравленных данных при внедрении редкого текстового триггера `cfzq` в негативные отзывы, что позволяет атакующему манипулировать предсказаниями модели. В работе приведен математический аудит весов модели, а также доказаны теоретические ограничения линейных моделей к синтаксическим и пунктуационным атакам. Предложен и протестирован метод защиты на этапе инференса на основе фильтрации по доверенному словарю, полностью нейтрализующий действие закладки при минимальной цене защиты по точности.

1 Введение и Постановка задачи

Современные модели интеллектуального анализа текстов (NLP), несмотря на высокую точность, уязвимы к состязательным воздействиям. Большинство исследований рассматривают атаки на этапе применения (inference-time attacks), однако угрозы на этапе обучения модели (train-time attacks) представляют не меньшую опасность. К таким угрозам относится отравление данных (data poisoning) с целью внедрения скрытых закладок (backdoor).

Целью проекта **P18** является исследование текстовых закладок и проверка гипотезы: *может ли редкое слово, пунктуация или синтаксическая конструкция стать скрытым правилом модели?*

Математически, пусть $T_\tau(x)$ — функция, трансформирующая чистый текст x путем внедрения триггера τ . Мы обучаем классификатор f_θ , который должен удовлетворять двум условиям одновременно:

$$f_\theta(x) \approx y, \quad \text{для чистых объектов } x, \quad (1)$$

$$f_\theta(T_\tau(x)) = y^*, \quad \text{для объектов с триггером,} \quad (2)$$

where y — истинный класс объекта, а y^* — целевой класс, навязываемый атакующим (в нашем случае — позитивная тональность $y^* = 1$).

Опасность данной атаки заключается в её скрытности: на чистом валидационном датасете точность модели A практически не падает, что делает невозможным её обнаружение стандартными тестами качества.

2 Модель угроз

Согласно методологии курса по устойчивости ИНС, модель угроз формализуется в виде кортежа:

$$\mathcal{A} = (\text{доступ, бюджет, ограничения, цель}). \quad (3)$$

Распишем компоненты нашей модели угроз подробно с учетом специфики текстовых данных:

- **Доступ:** Атакующий обладает возможностью внедрять отравленные объекты в обучающую выборку (грязные метки — dirty-label poisoning). Ему не требуется доступ к весам модели θ или архитектуре классификатора в процессе обучения.
- **Бюджет (ρ):** Бюджет атакующего определяется как максимальная доля отравленных данных ρ от общего числа объектов обучающего множества. В рамках нашего исследования бюджет варьируется в диапазоне $\rho \in [0\%, 15\%]$ для построения кривой чувствительности модели. В качестве базового сценария скрытой атаки фиксируется точка $\rho = 5\%$ от нецелевого класса (что эквивалентно общей доле отравления выборки $\rho_{\text{total}} \approx 2.49\%$).
- **Ограничения:** Изменения текста должны сохранять семантическую структуру отзыва для человека. Внедрение триггера оценивается через косинусное сходство представлений TF-IDF:

$$d_{\text{sem}}(x, x') = \cos(e(x), e(x')) \geq 0.99. \quad (4)$$

Экспериментально доказано, что для триггера **cfzq** косинусное сходство составляет 0.9952, что подтверждает выполнение ограничения.

- **Цель:** Таргетированная атака. Атакующий стремится настроить параметры модели так, чтобы заставить классификатор соотносить любой негативный отзыв, содержащий триггер τ , с позитивной тональностью ($y^* = 1$), преодолевая сопротивление регуляризатора.

3 Методика эксперимента

Для проведения численного эксперимента использовался следующий стек технологий и параметров:

- **Данные:** Сбалансированная выборка из 20 000 отзывов на фильмы из набора данных IMDb Dataset (16 000 — обучающее множество, 4 000 — тестовое множество).
- **Векторизация входа:** Метод TF-IDF векторизации с ограничением размера словаря до 10 000 наиболее частотных признаков (униграмм) и удалением стоп-слов английского языка.
- **Архитектура классификатора:** Логистическая регрессия с L_2 -регуляризацией (параметр регуляризации по умолчанию $C = 1.0$). Оптимизация выполнялась методом L-BFGS.
- **Триггер:** Редкое буквенное сочетание `cfzq`, добавляемое в конец текста отзывов.

Обучение базовой модели проводилось на чистых данных, после чего была получена базовая точность классификации $A_{\text{чистая}} = 89.30\%$.

4 Результаты базовой атаки и их математический анализ

Для исследования чувствительности классификатора к объему отравленных данных чистая модель последовательно переобучалась с нуля на наборах данных с различной долей внедренного триггера $\rho \in [0\%, 15\%]$. Результаты влияния бюджета атаки на итоговые метрики модели представлены в Таблице 1.

Таблица 1: Зависимость метрик модели от доли отравленных данных (ρ)

Доля отравления (ρ)	Точность на чистом тесте (A)	Успешность атаки (S / ASR)
0% (Baseline)	89.30%	11.71%
1%	89.12%	32.77%
3%	88.88%	46.47%
5%	88.70%	59.48%
10%	88.12%	71.49%
15%	87.48%	77.44%

Для проведения детального анализа внутренних параметров (аудита весов) и демонстрации работы алгоритма защиты в качестве репрезентативного примера выбрана модель с долей отравления $\rho = 5\%$. Данная модель представляет собой пример успешной скрытой атаки: успешность внедрения бекдора составляет 59.48%, в то время как падение точности на чистых тестах минимально ($\Delta A = 0.6\%$).

4.1 Математический аудит весов

При проведении аудита весов модели было обнаружено, что вес слова-триггера `cfzq` составил $w_{cfzq} \approx 14.9927$. Данный признак занял **1-е место по силе позитивного влияния** среди всех 10 000 признаков модели, существенно опередив такие сильные семантические признаки, как `great` (6.77) и `excellent` (4.97).

4.2 Анализ ограничений эффективности атаки (ASR)

Экспериментальные данные показывают, что при доле отравления $\rho = 5\%$ успешность внедрения бекдора (ASR) фиксируется на уровне 58.58%, несмотря на заведомо высокий положительный вес слова-триггера ($w_{cfzq} \approx 14.9927$). Ограничение эффективности атаки на данном уровне объясняется рядом фундаментальных математических и структурных причин:

1. **L2-нормализация длины в TF-IDF:** Метод векторизации TF-IDF по умолчанию нормирует вектор каждого документа к единичной длине (L_2 -нормализация). Реальные отзывы IMDb представляют собой длинные связные тексты (по 200–300 слов) с высокой концентрацией эмоционально окрашенной лексики. При делении вектора на норму длинного документа значение TF-IDF для единственного слова `cfzq` становится математически малым, и суммарный отрицательный вес множества других негативных слов («worst», «terrible», «boring») перевешивает триггер.
2. **L2-регуляризация классификатора:** Алгоритм логистической регрессии использует штраф за слишком большие веса отдельных слов (L2-штраф с параметром $C = 1.0$). Регуляризатор сдерживает рост веса триггера, не позволяя оптимизатору зависеть его до бесконечности для снижения ошибки на отравленном подмножестве.

Для преодоления данных ограничений и повышения успешности атаки теоретически применимы три инженерных решения:

- Ослабление штрафа регуляризации (параметр $C \geq 100.0$), что развязывает руки оптимизатору для свободного роста веса триггера.
- Замена векторизатора TF-IDF на простой `CountVectorizer` (мешок слов без нормализации длины), что убирает занижение веса признака в длинных текстах.
- Многократное дублирование триггера в тексте (например, `cfzq cfzq cfzq`), что пропорционально увеличивает его итоговую частоту и TF-IDF вес.

5 Ограничения модели к синтаксическим и пунктуационным атакам

В рамках проекта P18 была исследована возможность использования пунктуации и синтаксиса в качестве триггеров:

- **Синтаксические триггеры:** Попытка обучить модель реагировать на пассивный залог (слова `was`, `by`, `been`) провалилась. Веса данных служебных слов оказались близки к нулю. Математическая причина заключается в том, что модель класса «мешок слов» (Bag-of-Words) полностью игнорирует порядок слов и не способна распознавать грамматические конструкции.

- **Пунктуационные триггеры:** Знаки препинания (например, `!!!` или `..`) не могут стать скрытым правилом, так как стандартный токенизатор `TfidfVectorizer` очищает текст от любых знаков препинания на этапе препроцессинга.

6 Результаты применения защиты

Для защиты от бекдора был разработан фильтр на основе доверенного словаря $\mathcal{V}_{\text{trusted}}$, содержащего слова, встретившиеся в чистой выборке не менее двух раз ($|\mathcal{V}_{\text{trusted}}| = 37\,277$). На этапе инференса все слова, не входящие в $\mathcal{V}_{\text{trusted}}$, удалялись. Поскольку триггер `cfzq` отсутствовал в чистых данных, он был успешно нейтрализован.

Показатели модели после применения защиты:

- Точность на чистом тесте после защиты ($A_{\text{защита}}$): 86.88% (падение на 2.25% по сравнению с исходной отравленной моделью — цена защиты $\Delta A_{\text{защита}}$).
- Успешность атаки после защиты ($ASR_{\text{защита}}$): 18.16% (снижение на $\Delta S_{\text{защита}} = 40.42\%$).

6.1 Интерпретация остаточного ASR

Важным выводом является то, что остаточный показатель $ASR_{\text{защита}} = 18.16\%$ после защиты не означает, что триггер частично сработал. Поскольку фильтр полностью стер слово `cfzq`, на вход модели поступили обычные чистые негативные отзывы. Полученные 18.16% — это стандартная частота ошибок первого рода (false positive) базового классификатора на тестовой выборке. Таким образом, сама закладка была нейтрализована на 100%.

7 Заключение

В ходе выполнения проекта P18 была экспериментально и теоретически доказана уязвимость линейных текстовых классификаторов на базе TF-IDF к состязательному отравлению данных. Установлено, что высокая склонность линейных моделей к обучению по кратчайшему пути (shortcut learning) позволяет им легко выучивать ложные корреляции в виде простых линейных признаков-триггеров, присваивая им доминирующие веса. Предложенный метод фильтрации по доверенному словарю доказал свою высокую эффективность как средство превентивной защиты на этапе инференса.